

종합설계프로젝트 2 주차별 보고서

과목명	종합설계프로젝트 2
팀명	엘렌조
팀원	김도현, 신현우, 하성민, 최윤호
주차	2주차

2 주차 — 요구사항 정의 및 기술 스택 조사

수행 내용

- 핵심 요구사항 2 가지 정의: ① 대화 맥락 관리(Context window 한계 극복, 계층적 메모리 구조) ② 오프라인 동작(Zero-Data-Leak, 네트워크 제약 없는 독립 운용)
- 보안을 오프라인 LLM 채택의 핵심 근거로 설정 (민감 정보 및 음성 데이터의 외부 전송 차단)
- LLM 모듈 사전 연구: LoRA, Quantization, QLoRA 등 경량화 기법 조사
- 실험 장비 환경 확인: Windows x64, DDR4 RAM 16GB, CPU-Only(Intel i5U 4core)을 하한으로 기준 설정

이슈 / 리스크

- 리스크: (발생 가능성) 중 / (영향도) 높음 - CPU-only 환경에서 LLM 추론 속도 저하 우려 / (대응 계획) QLoRA + GGUF 양자화 사전 검토

다음 주 계획

- 기반 LLM 모델 선정(EXAONE-3.5 및 qwen 2.5 등 다양한 한국어 llm 검토)
- 개발 환경 세팅(Git action, conda 환경 통일, 로컬 llama.cpp 빌드)

회의록 / 피드백

일시/장소	2주차 (오프라인)
참석자	김도현, 신현우, 하성민, 최윤호
논의 내용	요구사항 2대 축(맥락 관리/오프라인) 확정, 모듈별 사전 연구 결과 공유
결정 사항	Zero-Data-Leak을 핵심 가치로 설정, 3계층 메모리 구조 방향성 수립
Action Item	LLM 경량화 기법 조사 / 1주 내

회의 사진

