

# 종합설계프로젝트 2 주차별 보고서

|     |                    |
|-----|--------------------|
| 과목명 | 종합설계프로젝트 2         |
| 팀명  | 엘렌조                |
| 팀원  | 김도현, 신현우, 하성민, 최윤희 |
| 주차  | 4주차                |

## 4 주차 — 모듈별 프로토타입 구현

### 수행 내용

- 대화 기반 LLM 프로토타입 구현(Exaone 3.5-2.4B 기반, llama-server HTTP 스트리밍)
- FastAPI 비동기 서버 골격 구축 - WebSocket 실시간 통신 + SQLite 기반 메모리 관리 설계 착수
- STT 는 Whisper(Large-v3) 파인튜닝 방향, TTS 는 VITS/Coqui TTS + KSS Dataset 활용 방향으로 설정
- RTX A6000 기반 파인튜닝 환경 구축 착수(음성 데이터셋 전처리)
- 논문 기반 2 계층 메모리 모듈 설계

### 이슈 / 리스크

- 이슈 1: (상황) CPU 환경에서 LLM 첫 토큰 생성까지 20~30 초 지연 발생 / (영향) 실시간 대화 체감 저하 / (대응) 추후 경량화 기법 적용 예정 / (기한) 지속 모니터링
- 2 계층 메모리 설계로 테스트 시 맥락 상실 이슈 발생

### 다음 주 계획

- STT 인식률 및 전체 파이프라인 지연 시간(latency) 측정
- 중간발표 자료 준비

### 회의록 / 피드백

|             |                                      |
|-------------|--------------------------------------|
| 일시/장소       | 4주차 (오프라인)                           |
| 참석자         | 김도현, 신현우, 하성민, 최윤희                   |
| 논의 내용       | 모듈별 프로토타입 동작 확인, 통합 파이프라인 방향 논의      |
| 결정 사항       | FastAPI orchestrator 중심 구조로 통합 진행    |
| Action Item | STT 인식률 측정 / SLM 경량화/ 계층 메모리 발전 1주 내 |

## 회의 사진

