

# 종합설계프로젝트 2 주차별 보고서

|     |                    |
|-----|--------------------|
| 과목명 | 종합설계프로젝트 2         |
| 팀명  | 엘렌조                |
| 팀원  | 김도현, 신현우, 하성민, 최윤희 |
| 주차  | 7주차                |

## 7 주차 — 학습 데이터 구축 및 QLoRA 파인튜닝 설계

### 수행 내용

- GPT-4o 를 활용하여 한국어 아동 대화 샘플 1,500 개 생성 - 감정 공감/호기심·지식/거부상황/관계·사회성/페르소나 유지 5 개 카테고리에 균등 분포(각 300 개)
- system-user-assistant 멀티턴 채팅 템플릿 형식으로 데이터 구성, 반말·공감 응답·캐릭터 정체 유지 일관성 확보
- QLoRA 기반 파인튜닝 설계: 기반 모델 4bit NF4 양자화 고정, attention 모듈에 LoRA 어댑터 삽입(학습 파라미터 0.06%)
- LoRA rank 비교 실험 설계( $r=8, 16, 32$ ), 8-bit Paged AdamW optimizer, LoRA scaling factor 2, 3 epoch 학습 설정
- FastAPI Ochestrator 간 TTS 와 LLM 오버랩 타이밍 제어 코드 작성
- CPU 경합 메트릭 강구

### 이슈 / 리스크

- 이슈 1: (상황) 학습 데이터의 카테고리 편향 가능성 / (영향) 특정 상황에서 페르소나 붕괴 가능 / (대응) 5 개 카테고리 균등 분포로 데이터 설계 / (기한) 7 주차 완료
- 비동기 오버랩 모니터링 대책 찾지 못함

### 다음 주 계획

- $r=8/16/32$  각 조건별 독립 파인튜닝 수행
- GGUF 변환 및 양자화(Q4\_K\_M, Q5\_K\_M, Q8\_0) 적용

### 회의록 / 피드백

|             |                                                    |
|-------------|----------------------------------------------------|
| 일시/장소       | 7주차 (온라인)                                          |
| 참석자         | 김도현, 신현우, 하성민, 최윤희                                 |
| 논의 내용       | 학습 데이터셋 품질 검토, QLoRA 실험 변수(rank/양자화) 확정            |
| 결정 사항       | LoRA rank 3종 × 양자화 3종, 총 9개 모델 + 베이스 모델 비교 실험으로 확정 |
| Action Item | 파인튜닝 실험 착수 / 2주 내                                  |

회의 사진

