

종합설계프로젝트 2 주차별 보고서

과목명	종합설계프로젝트 2
팀명	엘렌조
팀원	김도현, 신현우, 하성민, 최윤희
주차	8주차

8 주차 — QLoRA 파인튜닝 실행 및 GGUF 변환

수행 내용

- LoRA rank 8/16/32 각 조건에 대해 독립적인 QLoRA 파인튜닝 수행(동일 데이터셋, 3 epoch)
- 파인튜닝 완료된 LoRA 어댑터를 기반 모델과 병합 후, llama.cpp 의 convert_hf_to_gguf 도구로 FP16 GGUF 형식 변환
- Q4_K_M, Q5_K_M, Q8_0 세 가지 양자화 방식 적용 - rank 3 종 × 양자화 3 종 조합으로 총 9 개 파인튜닝 모델 생성
- 평가용 베이스 모델 1 개 추가하여 총 10 개 모델 준비 완료
- 모듈 통합 후 목표 TTFT 인 5 초를 초과한 8 초로, fastAPI 스레드풀 방식 사용

이슈 / 리스크

- 이슈 1: (상황) GPU(RTX 4080) 학습 환경과 실제 배포 환경(CPU-only)의 차이 / (영향) 평가 시 CPU 전용 환경에서 재검증 필요 / (대응) 평가는 llama-server 기반 CPU 전용 환경에서 수행 / (기한) 9 주차
- 스레드풀을 나눴음에도, CPU 물리 코어 경합 발생 / 다른 대책 강구

다음 주 계획

- 10 개 모델 정량 평가(TTFT, TPS, RAM, 페르소나 일관성 P) 수행
- Human Verification 절차 진행
- CPU 4 코어 물리 코어 경합 대책 강구

회의록 / 피드백

일시/장소	8주차 (오프라인)
참석자	김도현, 신현우, 하성민, 최윤희
논의 내용	파인튜닝 및 양자화 진행 상황 공유, 평가 지표 설계 논의, 모듈 통합 논의
결정 사항	TTFT/TPS/RAM/페르소나 일관성(P) 4개 지표로 평가 진행, 스레드풀 나눔
Action Item	10개 모델 정량 평가 수행 / 1주 내, 시스템 개선 방안 강구

회의 사진

