

종합설계프로젝트 2 주차별 보고서

과목명	종합설계프로젝트 2
팀명	엘렌조
팀원	김도현, 신현우, 하성민, 최윤희
주차	9주차

9 주차 — 모델 평가 및 최적 조합 선정, 2 차 중간발표

수행 내용

- Intel Core i5 / 16saGB RAM / Windows 11 CPU 전용 환경에서 10 개 모델(베이스+9 개) 평가 수행
- 평가 결과: base_q4km(P=31.2%) 대비 파인튜닝 모델 최대 P=84.1%로 향상, r8 계열 평균 P 81.9% vs r16/r32 각 63.2%/61.5% - 단순 페르소나 태스크에서 낮은 rank 가 더 우수함을 확인
- Q4_K_M 이 Q5_K_M 보다 파일 크기는 작지만 런타임 RAM 을 약 2.4GB 더 사용하는 역설적 현상 발견 - llama.cpp 의 CPU_REPACK 최적화 메커니즘으로 원인 규명
- 최적 모델로 r8_Q5_K_M 선정(P=84.1%, RAM 5.15GB, TPS 6.09) - 2 차 중간발표에서 해당 결과 발표
- tts 는 RTF 0.271 로 실시간 처리 기준을 충족하는 LoRA ONNX FP32 채택, INT8 은 오히려 성능이 떨어짐을 확인'
- 시스템 통합 간 병목 탐색을 위해 실제 여러 번 테스트 수행 및 메모리 모듈 sqlite lock 경합 해소

이슈 / 리스크

- 이슈 1: (상황) Q4_K_M 이 파일 크기 대비 런타임 RAM 을 더 많이 사용하는 역설 발견 / (영향) 단순 파일 크기 기준 모델 선택 시 오판 위험 / (대응) CPU_REPACK 메커니즘 분석 후 런타임 RAM 기준으로 평가 기준 수정 / (기한) 9 주차 완료

다음 주 계획

- 선정 모델을 실제 파이프라인(STT-TTS-BE)에 통합
- 논문 투고 준비(COLQ, 시스템 논문)

회의록 / 피드백

일시/장소	9주차 (오프라인, 중간발표)
참석자	김도현, 신현우, 하성민, 최윤희
논의 내용	10개 모델 평가 결과 공유, 최적 조합 선정 근거 논의
결정 사항	r8_Q5_K_M을 최종 LLM 모델로 채택
Action Item	전원 - 통합 파이프라인 구축 착수 / 2주 내

회의 사진

