

종합설계프로젝트 2 주차별 보고서

과목명	종합설계프로젝트 2
팀명	엘렌조
팀원	김도현, 신현우, 하성민, 최윤희
주차	10주차

10 주차 — 파이프라인 통합 및 Latency 문제 분석

수행 내용

- STT(Whisper+LoRA, CER 19.3% 개선)-LLM(r8_Q5_K_M)-TTS(MeloTTS+LoRA, ONNX 변환) 모듈을 FastAPI 비동기 서버로 통합
- 모듈 조립 후 2 번째 세션에서 첫 응답 지연 7.52 초 발생을 로그로 확인 - LLM TTFT(요청→첫 토큰) 6648ms 가 전체 지연의 핵심 원인으로 분석
- LLM 과 TTS 를 FastAPI 의 asyncio + ThreadPoolExecutor 로 분리(LLM Pool, TTS Pool size=2)하여 요청마다 스레드 생성하는 비용 제거
- Fastapi 자체 로깅 기반 단계별 latency 분석: STT 2.3s, SLM prefill 2.9s, decode 1.1s, TTS 0.9s - SLM prefill 이 가장 비용이 큰 CPU bound 연산임을 확인
- 각종 사례를 통한 시스템 오버헤드 개선안 모색 - apple siri

이슈 / 리스크

- 이슈 1: (상황) llama-server 가 CPU 4 코어를 점유하며 첫 응답이 직렬로 처리됨 / (영향) 물리적 연산 시간 자체는 단축 불가 / (대응) 연산 시간을 줄일 수 없다면 도메인(발화) 시간을 활용하는 방향으로 전환 / (기한) 11 주차

다음 주 계획

- Prefill Hiding 기법 설계 및 구현(발화 시간 동안 시스템 프롬프트 미리 처리)
- KV-cache 활용 최적화

회의록 / 피드백

일시/장소	10주차 (온라인)
참석자	김도현, 신현우, 하성민, 최윤희
논의 내용	통합 파이프라인 테스트 결과 및 latency 원인 분석 공유
결정 사항	Apple Siri 사례를 참고해 발화 시간을 무료 작업 슬롯으로 활용하는 전략 채택
Action Item	Prefill Hiding 구현 / 1주 내

회의 사진

