

종합설계프로젝트 2 주차별 보고서

과목명	종합설계프로젝트 2
팀명	엘렌조
팀원	김도현, 신현우, 하성민, 최윤희
주차	11주차

11 주차 — Prefill Hiding 적용 및 SLM 서빙 최적화

수행 내용

- Prefill Hiding 기법 구현 - 사용자 발화가 진행되는 동안 백그라운드 스레드에서 시스템 프롬프트(기억 모듈 포함)를 llama-server 에 미리 prefill 하여 KV-cache 에 저장
- 발화 종료 후 실제 LLM 요청 시 KV-cache hit 으로 prefill 단계를 스킵하고 첫 토큰을 즉시 발행하도록 구조 변경
- SLM 서빙 엔진 비교 검토(vLLM, TGI, SGLang, llama.cpp) - GPU 가정 설계인 vLLM/TGI 대신 CPU-only 표준인 llama.cpp 유지 결정
- EXAONE 이 JSON 으로 학습된 모델임을 고려해 TOON(Token-Oriented Object Notation) 도입 검토 - 토큰 약 30~60% 절감 가능성 확인

이슈 / 리스크

- 이슈 1: (상황) Prefill Hiding 적용 전후 성능 비교 검증 필요 / (영향) 실제 개선 효과 입증 부족 / (대응) Base(7.52s) vs Solution(평균 5.68s) 비교 실험 수행 / (기한) 11 주차 완료
- TOON 도입 불가 확정

다음 주 계획

- 최종발표 자료 준비 및 시연 영상 녹화
- 논문 최종 투고

회의록 / 피드백

일시/장소	11주차 (오프라인)
참석자	김도현, 신현우, 하성민, 최윤희
논의 내용	Prefill Hiding 적용 결과 및 성능 개선폭 검토
결정 사항	첫 응답 지연 7.52s → 평균 5.68s로 개선 확인, 최종발표 준비 착수
Action Item	전원 - 최종발표 자료 및 시연 영상 준비 / 1주 내

회의 사진

